Priorización de pacientes con alto riesgo de ACV para un programa de prevención

Proyecto final (entrega final del anteproyecto) - ST1613 Aprendizaje de Máquina Aplicado - Universidad EAFIT

Sergio Alfredo Junca Valero (trabajo individual)

Octubre de 2026

Resumen ejecutivo

Por qué. Un programa de prevención no puede citar a todos sus afiliados. Su regla, “edad ≥ 60 años o hipertensión”, cita al 30.8 % de los pacientes y capta el 78 % de los casos de accidente cerebrovascular (ACV). ¿Un modelo capta al menos el 80 % con menos citas?

Qué interesante. (1) El PR-AUC, la métrica de negocio y la parsimonia señalaron tres modelos distintos, con diferencias dentro del ruido: la métrica estándar habría escogido el que más citas cuesta. (2) La edad aporta el 63 % del peso, y con un solo umbral el modelo capta apenas 0.29 de los casos menores de 60 años.

Cómo lo resolvimos. Prueba sellada desde el inicio; *pipeline* sin fuga de datos; cinco variantes de cuatro familias con validación cruzada anidada y repetida (20 evaluaciones); ganador por casos captados con las mismas citas que la regla; umbral con recall ≥ 0.80.

Conclusión. Gana la regresión logística: con las mismas citas que la regla capta unos 2 casos más de cada 40 (+1.75; 15 de 20 evaluaciones), o un recall igual o mayor con 2 puntos menos de citas (29 % en lugar de 31 %). En la prueba (50 casos): recall 0.80 y +1 caso (IC 95 %: 0 a 4). La mejora es real pero moderada. **Sesgo por edad:** un umbral por grupo de edad sube el recall en menores de 60 de 0.29 a 0.79, a cambio de citar al 34.5 % en lugar del 29.1 %.

1. Pregunta de investigación y objetivos

Contexto y pregunta. Escenario supuesto: una EPS solo puede citar cada mes a una parte de sus afiliados y hoy los escoge con la regla “edad ≥ 60 o hipertensión”. El ACV es la segunda causa de muerte en el mundo y cuesta más de USD 721 000 millones (Feigin et al., 2022). Con datos demográficos y clínicos básicos, ¿se puede ordenar a los pacientes por riesgo mejor que con la regla, de forma que el programa capte al menos el 80 % de los casos citando a menos personas?

Objetivo general. Construir y validar un modelo de clasificación que estime la probabilidad de ACV de cada paciente y ordene la lista de citación.

Objetivos específicos y estado.

1. *Pipeline* reproducible sin fuga de datos. **Cumplido:** el notebook corre de cero en 2 a 3 minutos.
2. Comparar cuatro familias con validación cruzada. **Cumplido:** cinco variantes (tabla 2).
3. Captar más casos que la regla con las mismas citas y fijar el umbral con recall ≥ 0.80. **Cumplido con matices:** +1.75 de cada 40 en la validación anidada; +1 en la prueba (IC que incluye el cero).
4. Identificar los cinco factores de mayor peso. **Cumplido:** cuatro coinciden con la evidencia clínica; el segundo refleja la edad.

5. Reducir el sesgo por edad (pedido en la sustentación). **Cumplido con matices** (sección 4).

2. Datos para desarrollar el proyecto y análisis previo

Fuente y estado original. *Stroke Prediction Dataset* (fedesoriano, 2021): CSV de Kaggle con 5110 pacientes y 12 columnas. bmi traía “N/A” en 201 registros, smoking_status la categoría Unknown en el 30 % y había un registro con gender = Other. Se eliminaron ese registro y id: **5109 filas**, partidas en 4087 de entrenamiento (199 casos) y 1022 de prueba (50).

Tabla 1. Variables y transformaciones (ajustadas dentro del pipeline, solo con el entrenamiento).

Variable	Tipo	Descripción	Transformación
age, avg_glucose_level	Numéricas	Edad (0.08 a 82 años); glucosa promedio (mg/dL)	Escalado estándar
bmi	Numérica	IMC; “N/A” en 201 registros (3.9 %)	Mediana y escalado
hypertension, heart_disease	Binarias	Diagnóstico previo (0/1)	*One-hot*
gender, ever_married, Residence_type, work_type, smoking_status	Nominales	Sexo, estado civil, zona, empleo (5 categorías), tabaquismo (Unknown = 30 %)	*One-hot*
stroke (y)	**Binaria**	**1 = el paciente tuvo un ACV**	Partición estratificada

Variable dependiente y métrica. Solo el 4.87 % tuvo un ACV: un modelo que siempre diga “no ACV” acierta el 95 % y no detecta a nadie, así que **no se usó accuracy**. Los hiperparámetros se ajustaron con **PR-AUC** (Saito y Rehmsmeier, 2015), el ganador se eligió con **casos captados con las mismas citas que la regla** y se operó con **el umbral más alto con recall ≥ 0.80**. stroke dice si el paciente *ya tuvo* un ACV, no si lo tendrá: es la principal limitación de los datos.

Hallazgos del análisis exploratorio (figura 1, solo entrenamiento: la prueba no se tocó):

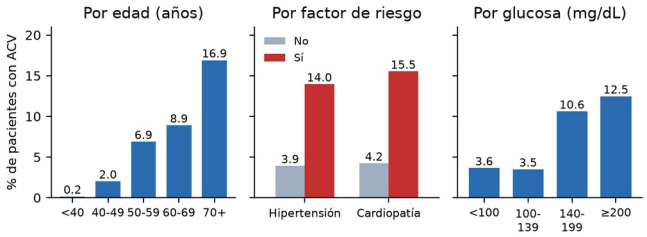


Figura 1. Tasa de ACV por edad, factor de riesgo y glucosa promedio (4087 pacientes de entrenamiento).

- **La edad domina:** de 0.2 % en menores de 40 años a 16.9 % en mayores de 70; es la correlación más alta con stroke (0.244) y ninguna llega a 0.25: señal real, pero débil y no lineal.
- **Hipertensión y cardiopatía multiplican el riesgo por 3.6 y 3.7**, y **la glucosa separa desde 140 mg/dL** (10.6 % y 12.5 %, frente a 3.5 % y 3.6 % por debajo de 140). El IMC casi no discrimina.
- **Unknown en tabaquismo:** el 44 % son menores de 18 años (tasa de ACV 3.1 % frente a 5.6 %); se dejó como categoría.

3. Metodología (CRISP-DM)

1. **Partición** 80/20 estratificada con semilla fija; la prueba se abrió una sola vez, al final.
2. **Preprocesamiento:** ColumnTransformer dentro de un Pipeline (Géron, 2019): imputación, escalado y codificación se ajustan solo con el entrenamiento de cada *fold*. **Desbalance:** class_weight='balanced' (un error en un caso de ACV pesa unas 20 veces más) frente a SMOTE (Chawla et al., 2002), este solo dentro del entrenamiento de cada *fold*.
3. **Iteraciones** (57 configuraciones, GridSearchCV con PR-AUC y 5 *folds*). Iteración 1: regresión logística L1 y L2, con class_weight o SMOTE (20), y kNN con SMOTE (10). Iteración 2: *random forest* (15) y *gradient boosting* (12). Sin redes profundas: con 199 casos una red no superó a la regresión logística (Kokkotis et al., 2022).
4. **Validación cruzada anidada y repetida:** el ciclo interno elige hiperparámetros; el externo (5 *folds* por 4 repeticiones: 20 evaluaciones de unos 817 pacientes y 40 casos) mide con datos que no participaron en esa elección, así que no se infla por probar muchas configuraciones.
5. **Ganador:** el que capte más casos con las citas de la regla; si otros quedan a menos de una desviación estándar entre *folds*, el más simple (variante de la regla de un error estándar; Hastie et al., 2009).
6. **Evaluación final:** una sola vez en la prueba, con IC *bootstrap* del 95 % (1000 remuestreos), recall por grupo y explicación con coeficientes y SHAP (Lundberg y Lee, 2017).
7. **Sesgo por edad:** umbral por grupo de edad y modelo sin las variables que reflejan la edad, en la misma validación anidada.

4. Resultados

Tabla 2. Validación cruzada anidada (20 evaluaciones fuera de muestra, promedios). "Casos extra": captados de más (± desviación estándar) con las mismas citas que la regla, por cada evaluación de unos 40 casos.

Modelo	Conf.	PR-AUC	Recall	Precisión	Citados	Casos extra	Supera a la regla
Regresión logística	10	0.185	0.796	0.134	29.1 %	**+1.75 ± 1.55**	15 de 20
Regresión logística + SMOTE	10	0.182	0.795	0.132	29.5 %	+1.55 ± 1.82	15 de 20
kNN + SMOTE	10	0.139	0.789	0.112	34.2 %	−1.60 ± 2.68	3 de 20
Random forest	15	0.193	0.812	0.140	28.2 %	+2.40 ± 1.67	19 de 20
Gradient boosting	12	**0.197**	0.849	0.118	35.2 %	+1.30 ± 2.62	11 de 20
Regla actual	-	-	0.779	0.124	30.8 %	0	-

Tres criterios, tres modelos. El PR-AUC habría elegido *gradient boosting*, el que más cita (35.2 %) y capta solo +1.30. La métrica de negocio señala al *random forest* (+2.40), pero su ventaja sobre la regresión logística, 0.65 casos, es menor que la desviación estándar (1.67): por parsimonia **gana la regresión logística**, que se lee coeficiente a coeficiente.

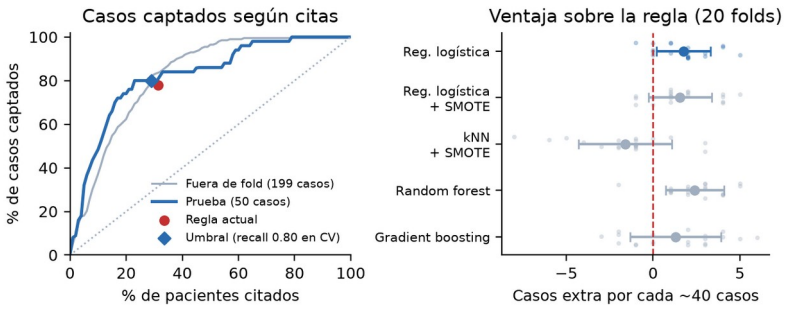


Figura 2. Izquierda: casos captados según citas. Derecha: casos extra frente a la regla en cada evaluación (puntos), con promedio y desviación estándar.

Prueba (una sola evaluación). Con el umbral 0.504 el modelo logró el recall previsto citando a menos pacientes que la regla (tabla 3). Con las mismas citas capta 40 casos y la regla 39: **+1, con IC 95 % de 0 a 4**. Coincide en signo con la validación anidada, pero con 50 casos la prueba sola no la demuestra. ROC-AUC 0.84; PR-AUC 0.26 (azar, 0.049).

Tabla 3. Evaluación única en la prueba, con IC 95 % bootstrap entre paréntesis.

Prueba (1022 pacientes)	Recall	Precisión	Citados	Casos con las citas de la regla
Regresión logística	0.800 (0.69-0.90)	0.135 (0.10-0.17)	29.0 % (26.2-31.5)	40 de 50 (+1; IC 0 a 4)
Regla actual	0.780	0.122	31.3 %	39 de 50

Puntos de operación (fuera de fold). Citar al 23.6 %, 28.5 % o 38.9 % de los pacientes capta el 70 %, 80 % o 90 % de los casos; cada punto de recall cuesta más citas al subir; la EPS escoge su margen.

Sesgo por edad. Con un solo umbral el modelo capta 0.99 de los casos de 60 años o más y solo 0.29 de los menores de 60 (tabla 4). Un **umbral por grupo de edad** con recall ≥ 0.80 en cada uno (igualdad de oportunidad; Hardt et al., 2016) los empareja a cambio de citar 5 puntos más; en la prueba, mirada solo para describir, capta 5 de 12 casos jóvenes en lugar de 2 (con 56 casos jóvenes de entrenamiento, ese umbral es inestable). **Quitar work_type y ever_married** no ayuda: eran la edad disfrazada. El modelo no cambia; el umbral por edad queda como opción de operación. Por sexo y zona no hay brecha concluyente.

Tabla 4. Recall por grupo de edad (20 evaluaciones; unos 11 casos menores de 60 en cada una).

Validación anidada	Recall < 60	Recall ≥ 60	Recall total	Citados
Regla actual	0.20	1.00	0.78	30.8 %
Regresión logística, un umbral	0.29	0.99	0.80	29.1 %
Con umbral por edad	**0.79**	0.80	0.80	34.5 %
Sin work_type ni ever_married	0.31	0.98	0.79	28.5 %

Qué pesa. La edad concentra el 63 % del peso (SHAP medio 1.61; la siguiente, 0.24). Edad, glucosa, tabaquismo e hipertensión coinciden con la evidencia clínica; work_type = children (555 menores, un ACV) es reflejo de la edad.

5. Revisión de la literatura

Factores de riesgo clínicos. El perfil de Framingham (Wolf et al., 1991) estima el riesgo de ACV con edad, presión arterial y su tratamiento, diabetes, tabaquismo, enfermedad

cardiovascular, fibrilación auricular e hipertrofia ventricular izquierda. Estos datos no traen fibrilación ni presión medida, lo que limita el desempeño. **Con las mismas variables:**

- **Dev et al. (2022)**, con 29 072 historias (548 casos), hallaron que edad, cardiopatía, glucosa e hipertensión concentran el poder predictivo (78 % de exactitud sobre una muestra balanceada) y lo proponen para asignar recursos, el uso de este proyecto.
- **Kokkotis et al. (2022)**, con 43 400 pacientes y validación anidada, obtuvieron el mayor AUC con regresión logística (0.833, cercano al 0.84 de este trabajo).
- **Tazin et al. (2021)** reportan 96 % de exactitud con *random forest* en este dataset, pero aplicaron SMOTE antes de partir: la prueba incluye casos sintéticos.

Brecha que cubre. Ninguno compara el modelo con la regla vigente ni traduce el resultado a citas; este proyecto sí, sin fuga de datos.

6. Plan

Al adelantarse la entrega, el modelado se comprimió a dos días, viable porque el piloto del 9 de octubre mostró que todo corre en minutos. Las dependencias son secuenciales (sin *pipeline* no hay modelo ni umbral, y la prueba se abre al final); tras la sustentación se agregó el análisis de sesgo por edad. Todo el material (presentación, notebook, datos y este documento) está en https://sjunka.github.io/acv-prevencion-ml/about/.

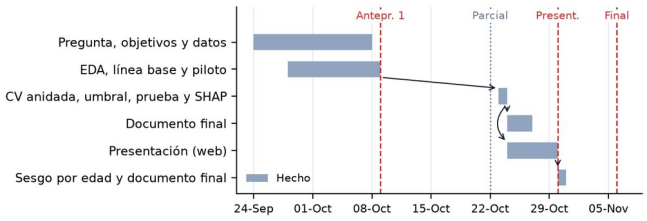


Figura 3. Diagrama de Gantt. Las flechas marcan dependencias, las líneas rojas las entregas y la gris el parcial.

7. Implicaciones éticas

- **Falsos negativos:** quien queda fuera de la lista no recibe prevención; con un solo umbral el modelo deja fuera a casi dos de cada tres casos menores de 60 años. Por eso el umbral prioriza el recall, existe la opción por edad y el médico debe poder agregar pacientes.
- **Falsos positivos:** con precisión de 0.135, unos 86 de cada 100 citados no tendrían un ACV: la cita se comunica como prevención, no como diagnóstico.
- **Sesgo y representatividad:** el recall se midió por sexo, zona y edad. El sesgo por edad se reduce con un umbral por grupo (sección 4), no se elimina: la etiqueta es histórica y hay pocos casos jóvenes. La fuente del dataset es confidencial: en Colombia hay que reentrenar con datos de la EPS.
- **Trabajo humano y ambiente:** no elimina puestos (el equipo pasa a revisar la lista); entrena en minutos en un portátil.
- **Fallas en producción:** si cambia la población, el desempeño cae sin aviso: se monitorea el recall por grupo de edad cada trimestre y, si baja de 0.80, se vuelve a la regla.

8. Aspectos legales y comerciales

- **Comercial:** focaliza el presupuesto de prevención: unos 2 casos más de cada 40 con las mismas citas, o unas 200 citas menos por cada 10 000 afiliados con recall 0.80. Sin costo por cita en los datos.
- **Legal:** los datos de salud son sensibles (Ley 1581 de 2012, art. 5 y 6): exigen autorización del titular o supresión de identidad; la historia clínica se rige por la Resolución 1995 de 1999 y la Ley 2015 de 2020.
- **Licencia:** dataset de uso educativo; en producción, datos de la EPS.

Referencias

Chawla, N. V., Bowyer, K. W., Hall, L. O. y Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321-357. https://doi.org/10.1613/jair.953

Dev, S., Wang, H., Nwosu, C. S., Jain, N., Veeravalli, B. y John, D. (2022). A predictive analytics approach for stroke prediction using machine learning and neural networks. *Healthcare Analytics*, 2, 100032. https://doi.org/10.1016/j.health.2022.100032

fedesoriano (2021). *Stroke Prediction Dataset* [conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/fedesoriano/stroke-prediction-dataset

Feigin, V. L., Brainin, M., Norrving, B., Martins, S., Sacco, R. L., Hacke, W., Fisher, M., Pandian, J. y Lindsay, P. (2022). World Stroke Organization (WSO): Global Stroke Fact Sheet 2022. *International Journal of Stroke*, 17(1), 18-29. https://doi.org/10.1177/17474930211065917

Géron, A. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow* (2.ª ed.). O'Reilly.

Hardt, M., Price, E. y Srebro, N. (2016). Equality of Opportunity in Supervised Learning. En *Advances in Neural Information Processing Systems 29* (NeurIPS 2016).

Hastie, T., Tibshirani, R. y Friedman, J. (2009). *The Elements of Statistical Learning* (2.ª ed.). Springer.

Kokkotis, C., Giarmatzis, G., Giannakou, E., Moustakidis, S., Tsatalas, T., Tsiptsios, D., Vadikolias, K. y Aggelousis, N. (2022). An Explainable Machine Learning Pipeline for Stroke Prediction on Imbalanced Data. *Diagnostics*, 12(10), 2392. https://doi.org/10.3390/diagnostics12102392

Lundberg, S. M. y Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. En *Advances in Neural Information Processing Systems 30* (NeurIPS 2017).

Saito, T. y Rehmsmeier, M. (2015). The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. *PLoS ONE*, 10(3), e0118432. https://doi.org/10.1371/journal.pone.0118432

Tazin, T., Alam, M. N., Dola, N. N., Bari, M. S., Bourouis, S. y Monirujjaman Khan, M. (2021). Stroke Disease Detection and Prediction Using Robust Learning Approaches. *Journal of Healthcare Engineering*, 2021, 7633381. https://doi.org/10.1155/2021/7633381

Wolf, P. A., D'Agostino, R. B., Belanger, A. J. y Kannel, W. B. (1991). Probability of stroke: a risk profile from the Framingham Study. *Stroke*, 22(3), 312-318. https://doi.org/10.1161/01.STR.22.3.312